厦門大學

本 科 毕 业 设 计

（主修专业）

学习驱动的心血管支架建模优化方法

A Learning-Driven Approach to Cardiovascular Stent Modeling Optimization

姓　　名：李钰轩

学　　号：22920212204139

学　　院：信息学院

专　　业：人工智能

年　　级：2021 级

校内指导教师：江敏 教授

二〇二五年四月三十日

厦门大学本科学位论文诚信承诺书

本人呈交的学位论文是在导师指导下独立完成的研究成果。本人在论文写作中参考其他个人或集体已经发表的研究成果，均在文中以适当方式明确标明，并符合相关法律规范及《厦门大学本科毕业论文（设计）规范》。

该学位论文为（　　）课题（组）的研究成果，获得（　　）课题（组）经费或实验室的资助，在（　　）实验室完成（请在以上括号内填写课题或课题组负责人或实验室名称，未有此项声明内容的，可以不作特别声明）。

本人承诺辅修专业毕业论文（设计）（如有）的内容与主修专业不存在相同与相近情况。

学生声明（签名）：

年　月　日

致谢

四年一闪而过，回想起 2021 年，仿佛还是昨天。

我仍然记得十二岁时想要成为医生的梦想，记得那本影响了我的书《无国界医生手记》。阴差阳错录取到计算机系后，大一时几度想要转专业，最终还是坚持了下来。尽管在过去的选择上有后悔的时刻，但人生不如意总是十之八九。不再去美化那条未曾选择的路，当下和未来总是更重要的，这大概是四年里我最大也最重要的心态转变。

感谢这三个多月里江敏教授的指导，为论文的完善提出诸多修改建议。实验过程中，我从开源资料和技术社区得到许多帮助和启发，谨向所有内容创作者致以诚挚的敬意。

谢谢我的妈妈和爸爸，教会我爱和被爱，非常幸运能做你们的女儿。

谢谢我最好的朋友们，和你们在一起的每个瞬间都美好而珍贵。

这是不完美的大学生活，但也还算难忘，感谢曾遇见的人，感谢经历过的事，感谢坚持到现在的自己。是 BE 还是 HE，不后悔就已经足够。论文落笔之际，对所有我爱的和爱我的人致以真诚的感谢，千言万语，尽在不言中。

最后用我很喜欢的一句歌词结尾吧，“其实人生 并非虚耗 何来尘埃飞舞”。

摘要

随着社会发展，心血管疾病严重威胁着人们的健康，其中动脉血管粥样硬化是发病的主要因素之一。血管支架植入手术是治疗动脉粥样硬化的常用手段，具有疗效快、术后并发症少等优点。心血管支架的结构影响着其性能和效果，因此在实际应用中，常常采用多物理场仿真建模的方法，调整设计参数，使得支架具有更优的参数。但是高精度的多物理场仿真会带来较高的计算代价，设计优化过程中也需要大量仿真数据，成为效率的瓶颈。本文提出了基于 NSGA-Ⅱ优化算法参数搜索和 Xgboost 提升树模型的优化方法，在不依赖高性能计算资源的前提下，更加快速准确地预测出支架性能的关键指标。具体研究内容如下：

分析心血管支架仿真建模在医疗领域的重要意义，结合目前存在的问题，提出 XGboost 和遗传算法联合建模的方法。

本文采用基于随机参数扰动与人工智能辅助生成的混合数值模拟方法，结合实际应用中心血管支架设计参数的合理工程范围，生成具有随机性和物理合理性的数据。实验中用 XGBoost 作为回归模型对数据进行训练，用于拟合输入的设计参数和输出的仿真结果之间的关系。同时结合 NSGA-Ⅱ优化了 XGBoost 的超参数，使得代理模型的预测误差更小、模型复杂度更低。将机器学习中的提升树模型和非支配排序遗传算法应用到心血管仿真建模的过程中，使原本高计算量、耗时更长的仿真工作变得快速，体现了机器学习和遗传算法在心血管仿真建模中的应用意义，同时也可以为心血管支架结构优化研究提供技术支撑。

关键词：心血管支架；NSGA-Ⅱ优化算法；Xgboost 提升树；参数搜索

Abstract

As society progresses, cardiovascular diseases emerge as a grave threat to public health. Among the various factors contributing to the development of atherosclerosis, the role of atherosclerosis itself is paramount. Vascular stent implantation is a prevalent treatment modality for atherosclerosis, characterized by its expeditious efficacy and minimal postoperative complications. The configuration of cardiovascular stents exerts a significant influence on their performance and effectiveness. Consequently, multi-physics field simulation modeling is frequently employed to adjust the design parameters, thereby optimizing the stents' performance. However, high-precision multi-physics field simulation incurs a substantial computational cost, necessitating a considerable volume of simulation data during the design optimization process, which can impede efficiency. In this paper, an optimization method is proposed. This method is based on genetic algorithm parameter search and Xgboost boosting tree model. The purpose of this method is to predict the key indexes of the stent performance ground more quickly and accurately. This is done without relying on high-performance computing resources. The specific research content is as follows:

The present study analyzes the significance of cardiovascular stent simulation modeling in the medical field. It proposes a joint modeling method of XGBoost and genetic algorithm in combination with the current problems.

In this paper, a hybrid numerical simulation method is employed. This method is based on random parameter perturbation and artificial intelligence-assisted generation. The method is used to generate data with randomness and physical reasonableness. This is achieved by combining the reasonable engineering range of cardiovascular stent design parameters in practical applications. XGBoost is utilized as a regression model to train the data in the experiment. This data is then employed to fit the relationship

between the input design parameters and the output simulation results. The hyperparameters of XGBoost were also optimized in conjunction with NSGA-II, resulting in smaller prediction errors and lower model complexity of the proxy model. The application of the boosted tree model and non-dominated sorting genetic algorithm in machine learning to the process of cardiovascular simulation modeling has been demonstrated to expedite the original simulation work, which was characterized by high computational demands and extended duration. This finding underscores the importance of incorporating machine learning and genetic algorithms in cardiovascular simulation modeling. Moreover, it provides a technical foundation for research endeavors aimed at optimizing the structure of cardiovascular stents.

Keywords： cardiovascular stent; Non-dominated Sorting Genetic Algorithm II; EXtreme Gradient Boosting; parameter sea

目录

第一章　绪论.....1

1.1　研究背景 1

1.2　心血管支架仿真建模的现状与挑战..... 2

1.2.1　心血管支架的结构与性能 2

1.2.3　心血管支架多物理场仿真建模的优势与挑战 4

1.3　机器学习和遗传算法在建模优化中的应用潜力..... 4

第二章　合成数据 7

2.1　合成数据概述 7

2.2　合成数据实验流程 7

2.2.1　支架参数与仿真指标的设定 8

2.2.2　合成数据的程序实现 8

2.3　合成数据的科学性和可用性分析..... 12

2.3.1　参数设定的物理合理性 12

2.3.2　数据结构的完整性 12

2.3.3　建模适用性 13

第三章　学习驱动的心血管支架建模优化方法.....15

3.1　心血管支架建模优化方法的需求..... 15

3.2　模型评价指标与方法 15

3.2.1　评价指标的设置 15

3.2.2　评估函数 16

3.3　XGBoost 模型..... 17

3.3.1　XGBoost 模型的构建.....18

3.3.2　XGBoost 与心血管支架仿真建模的适配性.....19

3.4　NSGA-Ⅱ优化算法 19

3.4.1　多目标优化问题背景 19

3.4.2 Pareto 最优解与支配关系 20
3.4.3 NSGA-Ⅱ的优化原理 20
3.4.4 NSGA-Ⅱ的优化过程 22
3.5 XGBoost+SGA 对照组 24
第四章 实验结果可视化与分析 25
4.1 XGBoost 与 NSGA-Ⅱ代理模型 25
4.2 NSGA-Ⅱ和 SGA 优化效果的比较 28
第五章 总结与展望 31
5.1 工作总结 31
5.2 不足与展望 31
参考文献 33

Contents

Chapter 1 Introduction.....1

1.1 Research Background.....1

1.2 Current Status and Challenges of Cardiovascular Stent Simulation Modeling.....2

1.2.1 Structure and Performance of Cardiovascular Stents 2

1.2.3 Advantages and Challenges of Multiphysics Simulation for Stents.....4

1.3 Potential of Machine Learning and Genetic Algorithms in Modeling Optimization 4

Chapter 2 Synthetic Data 7

2.1 Overview of Synthetic Data 7

2.2 Experimental Workflow of Synthetic Data.....7

2.2.1 Parameter and Metric Design for Stents 8

2.2.2 Programmatic Implementation of Data Generation.....8

2.3 Scientific Validity and Applicability Analysis of the Data 12

2.3.1 Physical Rationality of Parameter Settings.....12

2.3.2 Structural Completeness of the Data 12

2.3.3 Applicability for Modeling 13

Chapter 3 A Learning-Driven Approach to Cardiovascular Stent Modeling Optimization.....15

3.1 Requirements of the Optimization Method 15

3.2 Model Evaluation Metrics and Methods.....15

3.2.1 Evaluation Indicators 15

3.2.2 Evaluation Functions 16

3.3 XGBoost Model **17**

3.3.1 Construction of the XGBoost Model 18

3.3.2 Applicability of XGBoost to Stent Simulation 19

3.4 NSGA-II Optimization Algorithm **19**

3.4.1 Background of Multi-Objective Optimization 19

3.4.2 Pareto Optimality and Dominance 20

3.4.3 Optimization Principle of NSGA-II 20

3.4.4 Optimization Procedure of NSGA-II 22

3.5 XGBoost + SGA Baseline Group **24**

Chapter 4 Visualization and Analysis of Experimental Results **25**

4.1 XGBoost Surrogate Model with NSGA-II Optimization **25**

4.2 Comparison of Optimization Results: NSGA-II vs. SGA **28**

Chapter 5 Conclusion and Outlook **31**

5.1 Summary of Work **31**

5.2 Limitations and Future Directions **31**

References **33**

第一章 绪论

1.1 研究背景

随着社会发展与经济进步，人们的物质生活日益丰富，生活方式也随之发生了重大改变，而心血管疾病已成为全球范围内导致死亡率最高的慢性疾病之一。世界卫生组织发布的数据显示，2016 年，全世界约有 1790 万人死于心血管疾病（Cardiovascular Disease，CVD），占全球死亡总数的 31%，占非传染性疾病死亡人数的 44%，居于各种疾病之首。在 2024 年的世界卫生报告中，心血管疾病仍然是困扰人类的重大健康问题[1]。根据中国心血管病中心发布的数据，目前我国心血管病患者人数约为 2.9 亿，占到疾病死亡总人数的 40%以上，CVD 所导致的死亡率也居于首位。目前，中国 CVD 患病率和死亡率依然处于持续上升阶段，由此产生的医疗费用也呈现出逐年增长的趋势。作为全球范围内导致死亡率最高的疾病类型之一，对 CVD 的研究始终受到广泛关注。经皮冠状动脉介入治疗（percutaneous coronary intervention，PCI）是心血管疾病治疗的重要手段，其中的冠状动脉支架植入术具有微创性、高疗效等特点，在临床中被广泛应用。

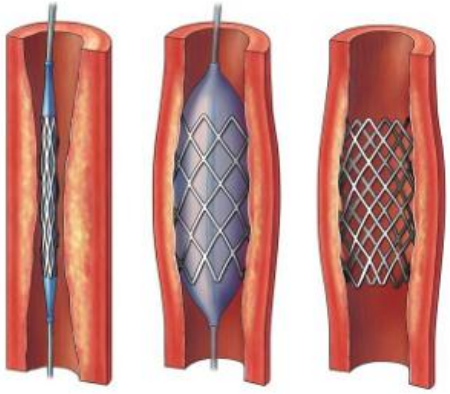

图 1-1 血管支架植入过程

支架植入极大改善了患者的生存质量，但植入后可能引起支架贴壁不良、支架内血栓、冠状动脉破裂等术后并发症，这仍然是临床应用中面临的重要挑战。

这些并发症可能影响患者远期预后、导致严重的再发事件。心血管支架的结构参数（如支架杆厚度、环间距、杨氏模量、支撑力等）对植入后的血流动力学环境、血管壁反应和再狭窄风险有直接且显著的影响。因此，支架设计优化不仅需要满足足够的径向支撑力和低回缩率，还需兼顾血流动力学特性，降低血管壁刺激和血栓形成风险。研究优化心血管支架的结构设计，是提高长期疗效、降低并发症发生率的重要研究方向[2]。

传统的血管支架设计与评估主要依赖有限元分析、计算流体动力学等仿真技术，这些方法精确模拟出支架植入后的多物理场行为，但也存在着单次仿真时间长、计算资源消耗大、建模过程繁琐等局限性。难以在短时间内满足多轮迭代优化的工程需求，尤其是在多目标、多约束的优化过程中，传统多物理场仿真方法效率较低的问题更加突出。本文针对心血管支架设计过程中对“仿真建模”这一部分的优化需求，探索一种能够在保证仿真准确性的同时，提升建模效率的方法，具有一定的理论意义与应用价值。

1.2 心血管支架仿真建模的现状与挑战

1.2.1 心血管支架的结构与性能

作为 PCI 中常用的植入医疗器械，心血管支架主要功能是撑开狭窄或闭塞的血管段，恢复血流通畅，防止血管再次狭窄。根据材料和功能的不同[3]，心血管支架分为裸金属支架（Bare-Metal Stents，BMS）[4]、药物洗脱支架（Drug-Eluting Stents，DES）[5][6]以及生物可降解支架（Bioresorbable Vascular Scaffolds，BVS）[7]等类型。

支架的基本结构通常由多个环状单元通过连接桥相连组成，即一系列的支撑环和连桥筋，如图 1-2 所示。支撑环为支架提供径向支撑力，桥筋把相邻两环连接在一起，可以提高支架在纵向的稳定性，关键的设计参数包括支架杆厚度、开孔形状、支撑单元间距等。此外，支架材料的弹性模量和屈服强度决定了其在扩张过程中的可控性与长期支撑能力。

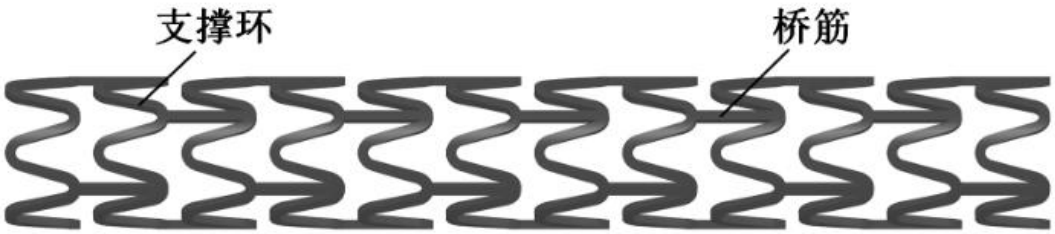

图 1-2 管状镂空型血管支架的支撑环和桥筋

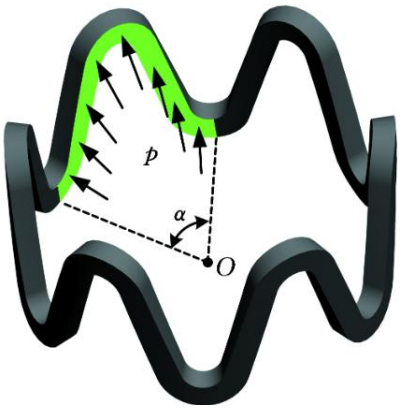

图 1-3 支撑环三维图

支架结构设计与其临床性能密切相关。较厚的支架杆能提供更大的径向支撑力，但可能增加血流阻力和血栓形成风险；较薄的支架能改善血流动力学环境，但可能会牺牲部分机械强度。可见对心血管支架性能的优化是在在多个性能指标中寻求最优的平衡，这个过程是需要大量仿真数据支撑的。

1.2.2 心血管支架的多物理场仿真建模

为了在进行植入手术前准确预测支架的力学行为与血流动力学影响，数值仿真成为重要的研究工具。目前的心血管支架仿真主要采用有限元分析（Finite Element Analysis, FEA）[8]和计算流体动力学（Computational Fluid Dynamics, CFD）[9]两种方法。

FEA 主要用于模拟支架展开、回缩、疲劳寿命等力学特性。通过对支架及血管壁进行网格划分，引入非线性材料模型和接触模型，准确模拟支架在球囊扩张或自扩张过程中的形变行为 FEA 还可评估支架在动态生理条件下的疲劳破坏风险，为材料和结构优化提供依据。

CFD 则主要用于分析植入支架后局部血流环境的变化。支架植入后会引起血流速度、压力分布及剪切应力场的重构，这些变化直接关系到血栓形成、再狭窄风险等重要生物反应。通过数值求解 Navier–Stokes 方程，CFD 揭示了血流动力学参数在支架区域的微观变化特征。

为了达到更真实反映支架植入后的血管环境的目的，现在采用更多的是多物理场耦合仿真方法，即将 FEA 与 CFD 结合起来，同时把力学变形与流体变化的双向影响纳入考虑。这种方法能够同时捕捉支架扩张导致血管壁形态变化，以及血管壁形态变化对局部血流特性的反作用，从而使得仿真得到的结果更接近真实的生理过程。

1.2.3 心血管支架多物理场仿真建模的优势与挑战

多物理场仿真建模在支架设计中具有显著优势，既能在植入前准确预测支架的关键性能指标，也让研究者可以系统评估不同结构参数组合对支架力性能的影响，从而在进行支架性能优化时有科学可靠的依据。

与此同时，传统的多物理场仿真方法也面临一些困境和挑战。心血管支架结构复杂，血管壁材料表现出高度非线性与各向异性特性，因此建模与求解过程极其繁琐。其次，多物理场仿真需要细致的网格划分和极小的时间步长，单次仿真时间较长，这制约了设计迭代的速度。特别当需要进行多目标权衡优化时，这一缺点则更加突出。因此，在保证仿真精度的前提下，寻找在精确的同时更高效的建模方法，对于心血管支架工程的研究有着实用意义。

1.3 机器学习和遗传算法在建模优化中的应用潜力

近年来，随着计算能力的提升与数据资源的丰富，机器学习在工程建模与仿真领域开始得到广泛的关注与应用。与传统的物理建模方法不同，机器学习依托于数据驱动的模式，通过对大量历史数据的学习，自动捕捉输入与输出之间复杂、非线性的映射关系，因此具有较强的预测能力和适应性。如今，机器学习逐渐扩展至个性化治疗、植入器械设计与优化等新兴领域。例如，采用机器学习模型预测冠状动脉血管内支架植入后的血流变化，取得了与高保真 CFD 仿真接近的结果，大幅缩短了仿真时间。这一类工作的成功证明了机器学习在支架仿真建模中

的科学性与可靠性。

其中，集成学习方法以其优秀的非线性拟合能力、低过拟合风险和良好的泛化性能，在医疗器械建模、生命科学、疾病预测等领域得到过成功应用。若是推广到心血管支架仿真建模中，应当能以更低的计算成本，在更短时间内对支架结构参数与性能指标之间的关系进行近似预测，从而提升建模的效率与灵活性。

遗传算法作为典型的进化优化方法，有着无需显式目标函数形式、适用于非线性复杂问题、多目标优化能力强等优势，特别是 NSGA-II（Non-dominated Sorting Genetic Algorithm II）优化算法，能够在多目标优化任务中有效地找到 Pareto 最优解集，兼顾多个性能指标之间的平衡。

查阅资料发现，在航空复合材料的结构设计中，已有采用机器学习代理模型结合遗传算法的实例，实现了多目标性能优化，有效降低了设计周期。同样的方法在医疗器械、人工关节优化、定制化植入物设计等领域也初见成效。

综上所述，本文所研究的基于机器学习与 NSGA-II的心血管支架建模优化方法，具有科学合理性与应用潜力。

第二章 合成数据

2.1 合成数据概述

合成数据是通过模仿真实世界数据的特征和模式，由计算机生成的数据集。尽管是人为的，但合成数据在数学、统计上反映了真实世界的数据。研究表明，合成数据在训练模型方面甚至可以实现同样好的效果。这会使模型训练更加简单有效，尤其是在无法使用、共享或移动真实数据的情况下。

获取大量医疗数据非常昂贵且耗时，尤其是在需要高精度设备和长期患者跟踪的领域。此外，大规模用于训练的数据通常从多个数据中心收集到某个集中机构，大大增加了患者隐私暴露的风险[10]。鉴于上述问题，使用合成数据可以成为一种有效的替代方法。

本文采用了物理合理性约束下的合成数据方法，批量构建出支架设计参数与仿真性能输出的数据集，为后续训练、优化机器学习代理模型做准备。实验在合成数据过程中遵循以下原则：

（1）在支架设计参数（输入参数）设定方面，依据心血管支架工程实践和临床应用中的经验，确定了五类核心设计变量，包括支架杆厚度、环间距、杨氏模量、血管管径、血流量。在支架性能指标（输出参数）设定方面，依据多物理场仿真与临床需求确定五个关键的响应变量，包括最大 Von Mises 应力、最大位移、径向强度、回缩率、压降。

（2）为了更好地模拟实际制造误差、生物变异及临床环境下的不确定性，避免数据过于集中或是缺乏变异性，引入了参数扰动机制。通过在合理范围内添加微小随机偏移，提升数据的分布广度和代表性，生成具有自然波动特性的样本。

（3）实验中所采用的合成数据方法在保证生成效率的同时，严格遵循物理规律，确保数据的科学性、合理性与应用价值。在生成数据集后，也会进一步与真实数据对比，确认数据的科学性与合理性。

2.2 合成数据实验流程

2.2.1 支架参数与仿真指标的设定

为了得到出适用于心血管支架仿真建模的数据集，在查阅了临床常见的支架设计参数以及生理环境特点后，最终设定了五个输入变量，即 2.1 中提到的支架杆厚度、环间距、杨氏模量、血管管径、血流量，具体设置如下：

（1）支架杆厚度：设置在 0.09–0.21mm 范围内，反映不同厚度支架在支撑强度与血流动力学性能之间的平衡关系。

（2）环间距：控制在 0.9–2.1 mm 之间，代表支架单元间的连接密度，影响支架柔顺性与局部血流扰动。

（3）杨氏模量：设定为 38–77 GPa，覆盖了新型生物可降解材料的弹性性能区。

（4）血管管径：选取 2.5–4.0 mm 的典型成人冠状动脉直径范围，确保模拟数据具备生理合理性。

（5）血流量：设置在 45–155 mL/s 范围内，对应不同运动状态或病理条件下冠状动脉的流量变化。

对应地，根据最重要、最常用的心血管支架性能参数，选取了 2.1 中提到的五个仿真输出性能指标，即最大 Von Mises 应力、最大位移、径向强度、回缩率、压降，具体设置如下：

（1）最大 Von Mises 应力（MPa）：反映支架局部材料极限承载能力，关系到结构疲劳与断裂风险。

（2）最大位移（mm）：衡量支架植入过程中的柔顺性与变形特性。

（3）径向强度（N）：表征支架抵抗血管收缩与保持通畅性的能力。

（4）回缩率（%）：表示支架从扩张状态回弹到自然状态时的尺寸变化，影响支架定位稳定性。

（5）压降（Pa）：量化支架植入后对局部血流动力学造成的压力损失，关联血栓形成风险。

上述参数的设定范围参考了现有的临床应用、工程实践与文献数据，以确保模拟数据的科学性与合理性。

2.2.2 合成数据的程序实现

本实验参考了博客“Using ChatGPT to build Synthetic Datasets”的方法创建数据集，原博客链接 https://www.mercity.ai/blog-post/using-chatgpt-to-build-synthetic-datasets。像 ChatGPT、Deepseek 这样的模型通常是在巨大的数据集上进行训练的，可以借助这一特性进行合成数据的任务，利用大语言模型（Large Language Model, LLM）的能力生成心血管支架仿真数据集[11]。

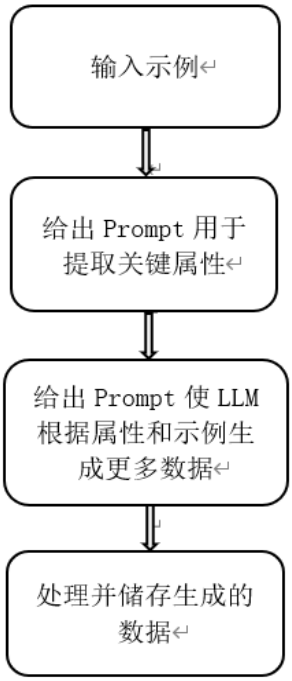

图 2-1 用于生成高质量合成数据集的 EXACT 管道

大模型内部学习的复杂非线性映射关系，可以近似模拟真实的多物理场仿真过程。Prompt 是驱动大模型的方式，大模型根据输入的 Prompt 给出用户想要的结果。通过工程约束引导的 Prompt，令 LLM 模拟仿真输出过程，从而有近似仿真器的效果[12]。本实验中调用了 DeepSeek 语言模型的 API，根据设定好的 Prompt 自动生成符合物理规律的完整仿真数据。为了得到高质量的合成数据，提供的 Prompt 要有足够的信息量，如图 2-2 所示。不同于传统多物理场仿真需要复杂的建模与求解，这个过程依托于大语言模型的推理与生成能力，快速输出符合指定约束的多物理场性能数据。

```
你是一个心血管支架仿真专家，需要生成多物理场仿真模拟数据。请注意增加参数的随机性与合理性，不要机械取
值。根据如下稍微扰动的实验设定，生成一条数据：

- 支架杆厚度（mm）：在 {thickness_min} ~ {thickness_max} 之间，随机选择，两位小数。
- 环间距（mm）：在 {spacing_min} ~ {spacing_max} 之间，随机选择，两位小数。
- 杨氏模量（GPa）：在 {modulus_min} ~ {modulus_max} 之间，随机选择，整数。
- 血管管径（mm）：在 {diameter_min} ~ {diameter_max} 之间，随机选择，一位小数。
- 血流量（mL/s）：在 {flow_min} ~ {flow_max} 之间，随机选择，整数。

仿真输出值也请体现一定随机性，但符合物理规律：
- 最大von Mises应力（MPa）：合理范围 200 ~ 400。
- 最大位移（mm）：合理范围 0.1 ~ 0.3。
- 径向强度（N）：合理范围 0.8 ~ 1.6。
- 回缩率（%）：合理范围 8 ~ 20。
- 压降（Pa）：合理范围 50 ~ 200。

【重要】：请直接以CSV格式输出，不要附加任何解释、空格或文本，字段顺序如下：
[支架杆厚度(mm)], [环间距(mm)], [杨氏模量(GPa)], [血管管径(mm)], [血流量(mL/s)], [最大von Mises应
力(MPa)], [最大位移(mm)], [径向强度(N)], [回缩率(%)], [压降(Pa)]
```

图 2-2 合成心血管支架数据的 AttrPrompt

通过上述流程生成了实验所需的心血管支架仿真建模数据，部分数据如表 2-1 所示。

表 2-1 部分合成数据

	支架杆厚度(mm)	环间距(mm)	杨氏模量(GPa)	血管管径(mm)	血流量(mL/s)	最大von Mises应力(MPa)	最大位移(mm)	径向强度(N)	回缩率(%)	压降(Pa)
1	0.17	1.45	58	3.7	112	327	0.21	1.23	14	128
2	0.14	1.27	52	3.2	87	287	0.18	1.2	14	112
3	0.17	1.45	63	3.7	112	287	0.21	1.23	14	128
4	0.17	1.28	58	3.7	112	287	0.21	1.3	14	128
5	0.14	1.72	52	3.7	89	287	0.18	1.2	14	112
6	0.14	1.37	52	3.8	112	287	0.18	1.2	14	128
7	0.17	1.32	58	3.2	112	287	0.18	1.24	14	128

表 2-1 部分合成数据（续）

	支架杆厚度(mm)	环间距(mm)	杨氏模量(GPa)	血管管径(mm)	血流量(mL/s)	最大von Mises应力(MPa)	最大位移(mm)	径向强度(N)	回缩率(%)	压降(Pa)
8	0.17	1.25	52	3.7	98	287	0.21	1.23	14	132
9	0.15	1.47	62	3.7	112	287	0.18	1.2	14	98
10	0.15	1.37	52	3.7	112	287	0.18	1.2	14	98
…	…	…	…	…	…	…	…	…	…	…
316	0.15	1.47	58	3.7	112	287	0.18	1.23	14	132

此外，实验中还在 Prompt 中引入了轻微扰动。编写生成 Prompt 的函数时在支架参数的设定部分引入了轻微扰动机制，即在每个输入参数x的基础上，增加一个小幅度的随机偏移δx:

$$x' = x + \delta x \tag{2.1}$$

其中的δx服从均匀分布：

$$\delta x \sim U(-\varepsilon x, +\varepsilon x) \tag{2.2}$$

这里的ε取一个较小的值，保证扰动在合理的物理范围内。这种扰动可以打破输入空间中数据样本的集中性，使得训练集更好地覆盖实际可能遇到的输入变异，提高模型的鲁棒性。

具体来说，在代码中利用 generate_prompt()函数动态生成 Prompt 时，输入参数范围在设定基础上引入小幅随机扰动。分别是支架杆厚度范围做微扰动模拟、环间距的最小值和最大值范围在小范围内轻微浮动、杨氏模量的上下限做整数微扰动、血管管径的内外径范围扰动、血流量模拟流体场仿真中流量变化的小扰动范围。上述设计保证生成样本之间的自然差异性，扩大数据分布，模拟实际制造

与临床环境中常见的物理波动。

本实验合成数据的任务中，每一条数据样本生成彼此独立，因此采用多进程机制处理，提高数据生成速度。采用 multiprocessing 模块创建多个进程，并行执行数据生成与写入操作。此外还合理设置了锁机制，避免多进程并发写文件时可能出现的数据冲突问题，从而保证数据文件的一致性与完整性。利用并行加速数据合成的工程优化思想，提高合成数据集构建效率，缩短数据生成总耗时。

所有生成的数据最终都以 CSV 格式统一规范存储，包含上述设置的输入参数与仿真输出指标，构建出结构清晰、在后续机器学习模型中可直接调用的合成数据集。

2.3 合成数据的科学性和可用性分析

由于本文中使用了合成数据集，因此验证其在应用中的科学性与可用性是必要的。以下从参数设定的物理合理性、数据结构的完整性和建模适用性三个维度对数据集进行分析，确定其适用于心血管支架建模的机器学习代理模型训练任务。

2.3.1 参数设定的物理合理性

选择的参数均参考了已有的支架设计方案进行设定，覆盖了心血管支架常用材料的工程特性和人体血管的典型生理参数[13]，与现有临床指南及文献报道的范围高度吻合。

冠状动脉支架直径通常为 2.0–5.0 mm；支架杆厚度略高于传统金属支架的典型值 60–100 μm，但符合生物可吸收支架（如 PLLA 支架）的设计特征。最大 Von Mises 应力（287–342 MPa）低于钴铬合金的屈服强度（400–600 Mpa），确保支架在负载下不发生塑性变形；径向强度（1.2–1.35 N）满足 ISO 25539-3 对支架抗塌陷能力的要求。 血流量（87–112 mL/s）与压降（98–132 Pa）覆盖静息至运动状态的生理范围（静息压降<5 mmHg，运动<10 mmHg）。

2.3.2 数据结构的完整性

合成数据以 CSV 格式存储，所有样本结构统一，字段完整，包含 5 个输入

变量与 5 个输出性能指标，在研究规模内可以满足机器学习模型初步训练与超参数搜索需求。数据集中无缺失值、格式规范，变量命名清晰，可直接用于机器学习模型中的训练与评估过程。

2.3.3 建模适用性

数据集应当具备适用于任务的特征，以下从变量之间的相关性方面进行分析。最大位移与支架杆厚度、径向强度正相关明显，支架越厚，越能抵抗形变，导致位移越小或更稳定；径向强度是结构整体刚性的体现，也与位移紧密相关，适合作为建模因变量。压降与杨氏模量、径向强度正相关，刚性越大、结构越硬，血液通过时阻力越大。回缩率和最大 Von Mises 应力属于较为复杂的函数输出，可能涉及多个变量间的耦合效应，具有非线性关系。血流量与压降与血管管径呈合理相关性，例如较小管径伴随更高压降，能够有效训练模型预测支架植入后的血流动力学响应。

此外，数据集具有明确的输入-输出映射结构，适合回归类建模；具有多个仿真性能指标，支持多目标建模与优化；样本数量中等，适合轻量或中等复杂度的代理建模。

第三章 学习驱动的心血管支架建模优化方法

3.1 心血管支架建模优化方法的需求

在医学建模与辅助决策系统的设计过程中，模型的评价指标不仅仅是整体误差或平均准确率，更关键的是对“错误类型”的区分与控制。特别是在心血管支架建模这一类涉及高风险决策的临床领域中，“第二类错误”（即将病理状态误判为正常状态）所带来的后果往往远比“第一类错误”（即将正常状态误判为病理）更加严重。例如，若模型在仿真中低估了某一支架参数下的峰值应力或疲劳集中区，则可能导致实际植入后的结构失效风险被忽视，从而引发严重的术后并发症。因此，所采用的机器学习模型不仅需要具备较高的整体准确率，还要在样本边界区域保持敏感性，尽量减少危险支架类型漏判的风险。选择一种能够逐步纠正错误、抑制第二类错误率上升，同时在小样本情况下具备良好泛化性能的机器学习算法，是用于心血管支架建模仿真的代理模型的必要需求[14]。

本文使用基于机器学习代理模型与遗传算法优化相结合的方法框架，选择 XGBoost 为基础构建支架性能预测模型，采用 NSGA-II 优化算法对 XGBoost（Extreme Gradient Boosting）的超参数进行多目标优化，兼顾模型准确率与复杂度，从而提高用于心血管支架仿真建模的代理模型整体效率与可靠性。实验中用两个模型版本进行比较，即 XGBoost＋NSGA-II算法和 XGBoost＋普通遗传算法（Simple Genetic Algorithm，SGA）。

3.2 模型评价指标与方法

3.2.1 评价指标的设置

为了评估 XGBoost 与 NSGA-II融合模型的建模能力和可用程度，设置了两个核心优化目标，分别从模型的复杂度与预测精度两个维度来衡量。

预测精度通过均方根误差（Root Mean Square Error，RMSE）来评价。RMSE

是衡量模型预测值或估计量与观测值之间差异的一种常用指标，它具有良好的数学稳定性与可解释性，反映了模型在数值拟合上的能力，可以直观展现模型偏离真实值的程度。实验中采用训练/测试集分割的方式对模型性能进行评估，训练集用于模型拟合，测试集用于计算 RMSE，公式为：

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{3.1}$$

其中，y_i是样本的真实响应值，$\hat{y}_i$是模型预测结果。

实际应用中还需要考虑代理模型结构的紧凑和简洁，使其更容易嵌入其他工具、在各种设备上运行，因此设定模型复杂度指标，用于衡量代理模型的结构负载能力，其表达式为：

$$ModelComplexity = n_{estimators} \times d_{max} \tag{3.2}$$

其中，$n_{estimators}$表示树的总数，d_{max}则表示每棵树的最大深度，该指标综合反映出了模型的结构规模与计算负载，适用于建模性能与资源开销之间的权衡。在之后的 NSGA-II多目标优化过程中，模型复杂度与 RMSE 共同构成目标函数，参与 Pareto 解筛选。

3.2.2 评估函数

如前文所述，评估函数中采用 RMSE 和 Model_Complexity 两个指标，对每一组超参数组合进行评价，即预测精度指标和模型复杂度指标，并在前一节内容的基础上进行了改进。

在计算 RMSE 时，实验中进一步使用交叉验证（Cross-Validation，CV），使评价结果更可靠，更能反映模型的泛化能力。交叉验证将数据集分割为 K 个互不重叠、大小相似的子集，如图 3-1 所示。

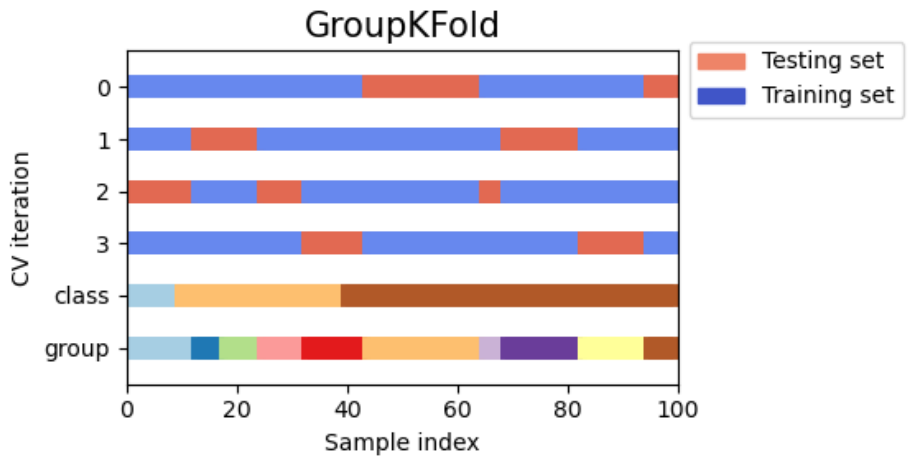

图 3-1 一个典型的五折交叉验证示意图

进行 K 次循环，在第 i 次循环中将第 i 个的子集作为验证集，剩下的 K-i 个子集合并起来作为训练集。在当前的训练集上训练模型，在当前的验证集上评估性能，并得到一个 RMSE。K 次循环结束后，计算这 K 个 RMSE 的平均值作为最终结果。代码中取 K=3，即进行三折交叉验证。

对于复杂度指标的计算，在公式（3.2）的基础上，用五个超参数的归一化调和平均数来计算复杂度指标：

$$Model\ Complexity_{harmonic} = \frac{n}{\sum_{i=1}^{n} \frac{1}{x_i + \varepsilon}} \tag{3.3}$$

其中x_i为每个归一化后的超参数值，ε为避免除零的微小常数。调和平均机制下，任何一个参数趋近于极小值时，整体复杂度显著降低，可以展现模型压缩优化的敏感性和有效性。

使用 XGBoost 模型进行训练，并计算出相应的 RMSE 与复杂度评分，之后 NSGA-II算法会以此作为适应度标准，在多代进化中逐步迭代出多个在精度与复杂度之间达到最优平衡的模型配置。

3.3 XGBoost 模型

XGBoost 是一种基于梯度提升树（Gradient Boosting Decision Trees, GBDT）

发展而来的高效集成学习方法，由 Chen 和 Guestrin 于 2016 年提出[15]。其核心思想是在每一轮迭代中，均训练一个新的弱学习器，以拟合前一轮模型残差的负梯度，从而逐步逼近最优模型。与传统线性模型或浅层树模型不同，XGBoost 在误差构成上呈现出偏保守倾向。在训练过程中更倾向于牺牲部分“无害”的第一类错误以压低第二类错误率，这一机制契合了医疗场景中的临床安全原则。

3.3.1 XGBoost 模型的构建

XGBoost 由一组加权的回归树组成，整体输出为多个子模型输出之和。在训练过程中根据上一轮的残差动态更新样本权重，并以梯度为导向构建下一轮树结构。为了确保模型结构具有灵活性与可调性，设定五个关键超参数：决策树数量$n_{estimators}$，树的最大深度d_{max}，学习率η，行采样比例s，列采样比例c。模型在训练集上进行拟合，并在测试集上输出预测结果，形成映射如下：

$$\hat{y} = f(x;\theta) \tag{3.4}$$

其中，$\hat{y}$为模型预测值，x为输入参数向量，θ为超参数组合。

XGBoost 构建一组加权决策树，每棵树根据特征划分数据空间并对叶子节点赋值，采用以下策略：

（1）结构正则化：在传统的梯度提升树模型中，过深、过多的树结构容易导致模型过拟合，尤其是在训练样本量有限、特征复杂度较高的情况下。XGBoost 引入结构正则化项对树的复杂度进行惩罚控制。控制每棵树的叶子数量，叶子越多，模型越复杂；控制叶节点的输出权重幅度，防止某些叶子在预测中贡献过大。本质上是通过正则化（Regularization）来压制训练集上的过度拟合行为，避免“训练准确、预测不准”问题。

（2）特征子采样：在训练每棵树时并不使用全部特征，而是从中随机选择一个子集进行分裂候选。该策略受随机森林方法的启发，打破特征之间的强相关性，从而减少模型对个别特征的依赖，提高了每棵树之间的差异性，增强集成效果。

（3）缺失值处理机制： XGBoost 采用自动学习缺失路径的方法，在训练过

程中，每次分裂节点时，都会同时评估“特征值缺失”时的默认去向，得到模型学习到某个特征缺失时应落入哪一侧分支，从而自动形成缺失响应机制。不需要外部预处理步骤、不会人为破坏数据分布结构，更适合应用于存在非结构化缺失或个别数据异常的医学领域建模任务。

在代码中，XGBoost 提取一组超参数作为输入，创建出回归模型，其中 n_estimators 和 max_depth 控制树的结构，将它们转为整数，其余参数仍为浮点型。n_estimators 控制 boosting 的轮数，每一轮都基于前一轮残差生成新的树；max_depth 限制单棵树复杂度，防止单棵树过拟合训练；learning_rate 是学习率，每棵树的输出都会乘以它，控制其贡献程度；subsample 是每轮训练所采样的样本比例，控制每棵树训练时的采样比例小于 1，防止过拟合；colsample_bytree 是每棵树训练使用的特征子集比例，用于增强模型鲁棒性、减少冗余特征影响。

3.3.2 XGBoost 与心血管支架仿真建模的适配性

在心血管支架仿真建模的场景中，输入参数维度多，与输出指标之间的关系高度非线性且不可显式建模。XGBoost 模型在此类任务中具有显著优势，因此将其作为核心预测模型[16]。

XGBoost 通过提升机制有效降低训练误差，对异常样本仍保持较高敏感性，兼具精度与鲁棒性。模型本身支持细粒度的概率输出与重要特征分析，在临床建模中不仅可以提供性能预测结果，还能辅助理解支架设计参数与性能之间的对应关系，提升模型的可解释性。算法中的参数结构清晰，方便之后 NSGA-II进行自动超参数调整。此外，它在医疗应用场景下对“第二类错误率”有着天然抑制能力，也是模型选择的重要依据。

3.4 NSGA-II 优化算法

3.4.1 多目标优化问题背景

构建心血管支架性能预测模型的核心目标是同时最小化预测误差与模型复杂度，前者保证预测结果的准确性，后者防止模型过拟合并提升其对未知支架设计的泛化能力。

这类多目标优化（Multi-objective Opimization Problem）的核心问题在于不同目标之间往往是相互冲突的。在多目标优化问题中，遗传算法（Genetic Algorithm，GA）作为一种基于自然选择与进化机制的优化方法被广泛应用[17]。GA 在解空间中进行全局搜索，通过种群进化、自适应变异、优胜劣汰等机制，有效识别多个目标的平衡解。传统的 GA 主要针对单目标问题，但通过框架扩展和改进也可用于多目标优化。

3.4.2 Pareto 最优解与支配关系

多目标优化问题中的多个目标函数之间往往存在冲突关系，由于这两个目标互为制约，因此无法通过传统单目标优化方法寻找最优解。为了解决这一问题，多目标优化采用了一种更具包容性的解构方式，即 Pareto 最优解集。

Pareto 解又称非支配解，由 Pareto 在 1986 年提出，其定义为：假设任何二解 S1 及 S2 对所有目标而言，S1 均优于 S2，则称 S1 支配 S2，若 S1 没有被其他解所支配，则 S1 称为非支配解。非支配解在多目标空间中构成 Pareto 前沿。沿着这个前沿线分布的所有解在不同目标之间实现了不同的平衡状态。某些解可能更倾向于精度，另一些则在模型的简洁性上有优势，但它们都代表了在现有条件下无法进一步改进的解集。在实际应用中，这种非支配性关系通过支配判定规则建立，可以根据支配关系对整个种群进行分层排序，形成多个 Pareto 等级。

这种机制的好处是优化算法无需强制在所有目标上取得最大化或最小化的统一解，而是提供一个解集供决策者选择。在心血管支架仿真建模的场景中，可以根据具体需求选择偏向于高精度或偏向于轻量化模型的方案，更贴合实际应用中多因素权衡的决策逻辑。

3.4.3 NSGA-Ⅱ的优化原理

NSGA-II是目前应用最为广泛的多目标优化进化算法之一，它在非支配排序遗传算法（Non-dominated Sorting Genetic Algorithm，NSGA）的基础上改进而来，具有高效的非支配排序机制、稳定维持解集多样性的能力、精英保留机制，在众多领域展现出优越的性能[18]。

NSGA-II的核心思想是：在每一代种群中，识别出那些在所有优化目标上没有被其他个体“全面压制”的方案，称为第一层次的非支配解。去除这些解后再次识别第二层非支配解，不断分层直到对整个种群排序完毕。这种机制确保每一代中最有价值的候选解被优先保留。

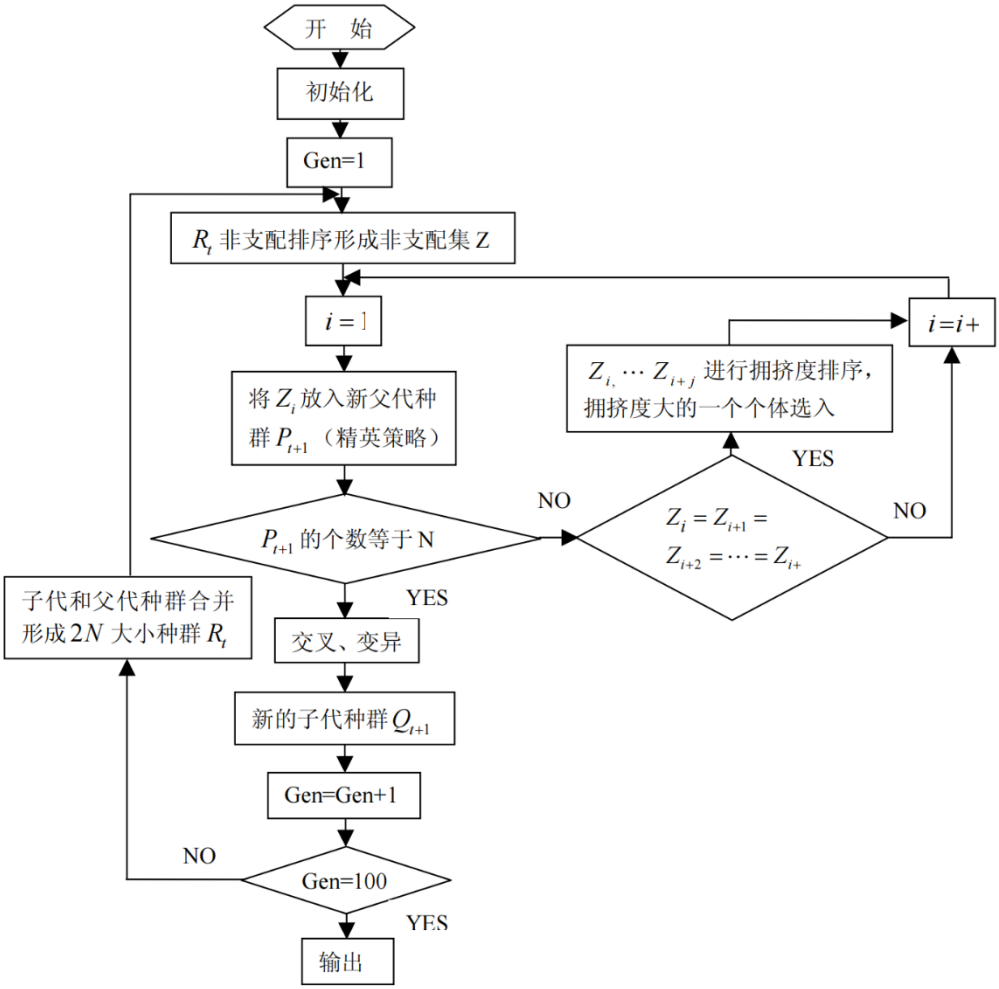

图 3-2 遗传算法流程图

为了稳定维持解集的多样性，NSGA-II中引入了拥挤度距离（Crowding Distance）的概念，用于衡量某一候选解在解空间中的稀疏程度，避免种群过度集中在某一小片区域。通过优先保留分布较稀疏的解，保持了解集在多个目标维度上的广泛分布，构建出较完整的 Pareto 前沿。

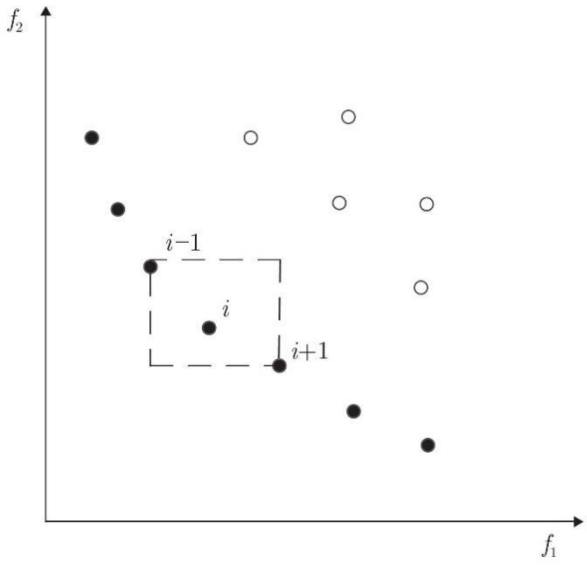

图 3-3 NSGA-Ⅱ算法中拥挤度距离计算的示意图

NSGA-II采用“精英策略”，在每轮演化中保留当前和上一代种群中最优的解集合，避免优秀解在演化过程中被意外淘汰。这一策略可以显著提升算法的稳定性和收敛能力。

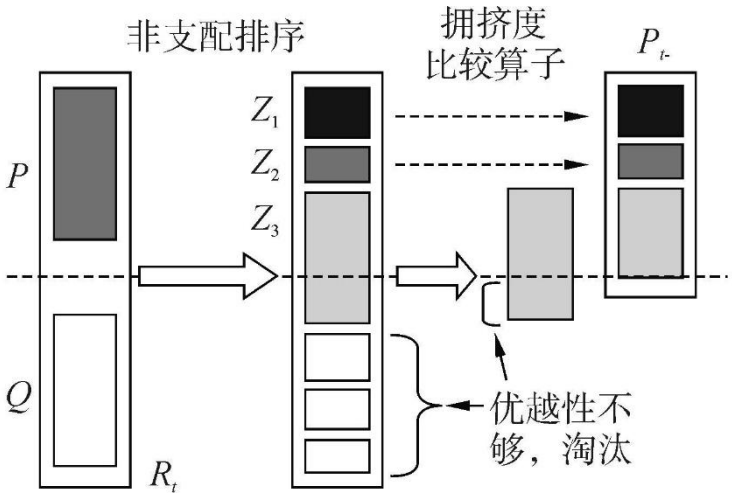

图 3-4 NSGA-Ⅱ算法中基于非支配排序与拥挤度距离的精英选择机制流程图

3.4.4 NSGA-Ⅱ的优化过程

NSGA-II作为多目标进化优化器，自动搜索超参数配置，以构建出兼具高精度与简洁性的代理模型。并且，NSGA-Ⅱ与代理模型具有高兼容性，适宜作为优化算法[19]。优化过程中结合非支配排序、拥挤度保持、精英策略与遗传演化等策略探索双目标冲突空间，生成满足不同需求的模型解集。

定义待优化的五个 XGBoost 超参数范围，并把每个个体θ_i作为一组超参数组合，即：

$$\theta_i = n_{estimators}，d_{max}，\eta, s, c \tag{3.5}$$

初始种群通过函数随机采样生成，确保初始搜索空间阶段具有良好的解空间多样性和覆盖全面性。对每一个体θ_i调用训练与评估函数，用于训练一个 XGBoost 模型，并返回 RMSE 和模型复杂度两个目标值。这两个值构成种群适应度的评价，是后续排序的多目标向量。

将种群中的个体依据两个目标的表现进行排序。识别出那些在两个目标上都不被其他个体“完全压制”的解，称为非支配解，这些解构成了第一层最优解集，其余个体依次构建第二层、第三层等较次优解集。非支配排序保证每轮优化都于关注当前表现最强的一批候选模型。快速非支配排序中，给定两个目标函数f_1和f_2，若解满足：

$$\begin{cases} f_1(a) \le f_1(b) \\ f_2(a) \le f_2(b) \\ 且存在k使得f_k(a) \le f_k(b) \end{cases} \tag{3.6}$$

则称 a 支配 b，未被任何其他个体支配的个体组成 Pareto 前沿。

为避免所有非支配解收敛至局部最优点或集中分布，在每一前沿内部引入拥挤度评估机制。计算每个解在目标空间中的分布密度，越靠边缘则距离越大，说明其代表的模型性能越独特；距离过近则可能意味着模型的冗余。算法中优先保留稀疏区域的解，用这种方式来提高解集的多样性。

在每一轮迭代中，NSGA-II会从当前的种群和新生成的子代中，选出最优秀的一部分个体作为下一代种群。采用精英策略，优先保留非支配层中的个体，如果一层放不下，就按照拥挤度选取，保证优秀的解不过早丢失，也可以促进多样性。

优化过程中的新解主要通过交叉与变异两种操作生成。交叉操作采用随机基因继承的方式，模拟基因重组的过程，随机组合两个父代的部分参数生成具有继

承特性的子代。变异操作则引入随机扰动，控制遗传突变概率为 10%，每个超参数都有一定概率被重新随机赋值，使新个体可能跳出原有的最优区域，达到进一步扩大搜索空间的效果。

上述流程重复执行多轮，直到满足实验中所设定的迭代次数。种群中模型的精度与复杂度的不断被优化，产生越来越靠近理想平衡的模型组合，最终输出一组在精度和复杂度之间表现优异的候选解集。

3.5 XGBoost+SGA 对照组

在本实验的对照组中，采用普通遗传算法对 XGBoost 模型的超参数进行单目标优化，最小化代理模型在多标签预测任务中的 RMSE。XGBoost 模型结构、数据预处理方式、特征与标签设置、交叉验证策略等均与 NSGA-II 优化实验保持一致，确保实验对比的公平性。两组实验的唯一区别在于优化算法本身。

SGA 算法在设定的参数边界范围内通过随机采样初始化若干个体构成种群，每个个体代表一组 XGBoost 的超参数组合。适应度函数采用三折交叉验证，每折针对所有输出标签分别训练 XGBoost 模型，并对每一标签计算 RMSE，最终取多标签平均 RMSE 作为当前个体的适应度。

种群进化过程中，SGA 使用锦标赛选择策略从当前种群中挑选适应度更优的个体作为父代；通过统一交叉操作生成子代，并以设定的概率对其进行基因变异以维持种群多样性。每一代迭代中均保留最优个体，确保算法收敛方向稳定。整个进化过程迭代 30 代，每代种群大小为 10，变异率设为 0.1。

实验记录了每一代的最优个体及其对应适应度，绘制出适应度收敛曲线并进行最终评估，在实验结果分析部分，对 SGA 优化的 XGBoost 代理模型和 NSGA-II优化的 XGBoost 代理模型进行评价和对比。

第四章 实验结果可视化与分析

4.1 XGBoost 与 NSGA-Ⅱ代理模型

为了清晰展示出 XGBoost+NSGA-II优化算法的效果，在结果分析中进行了必要的可视化操作。

（1）最终非支配解集分布：图 4-1 展示了第三十代非支配前沿中所有解在预测误差与模型复杂度维度下的分布情况。

图中的解分布密集且均匀，证明 NSGA-II在保证预测精度的同时有效控制了复杂度，最终获得了多组结构紧凑、误差低的高质量代理模型解。搜索结果是有选择性和收敛性的，集中在有潜力的区域。对于心血管支架仿真建模这一应用来说，无效、过拟合的模型被剔除了，有利于临床解释性。图像呈现明显的前沿曲线状，展现出性能-复杂度权衡关系。散点分布均匀，没有出现向右上角偏移的退化行为，说明进化没有陷入局部最优，保留了解的多样性。

整体来看 RMSE 和模型复杂度都有较为显著的下降，多目标优化结果有效且表现优秀。

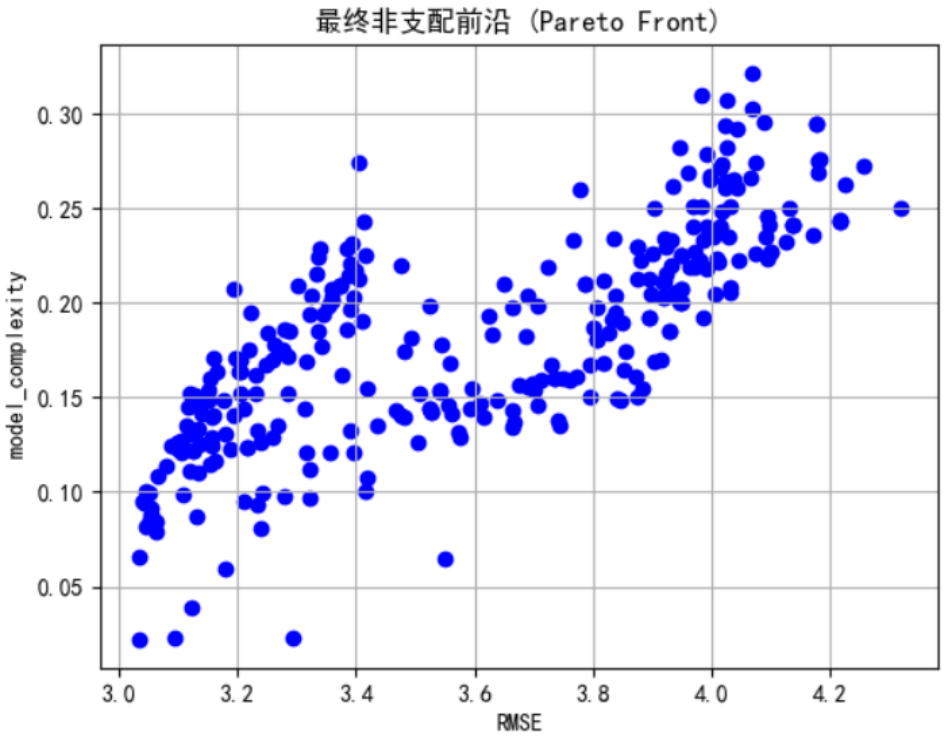

图 4-1 最终非支配前沿（Pareto Front）

（2）最终非支配前沿等级评分：在图 4-1 的基础上，通过颜色映射可视化最终代解的支配等级信息，刻画不同解在 Pareto 前沿中的相对优劣程度。横轴为 RMSE，纵轴为复杂度，颜色由深紫至亮黄渐变代表从支配等级最低（最优）到最高（次优），如图 4-2 所示。

从颜色分布可以看出这些解呈现明确的 Pareto 前沿结构。红色点区域覆盖较广，表示最终一代不仅找到了多个非支配解，而且这些解在不同区间内均有分布。说明算法保留了解的多样性，避免了早熟收敛到单一类型模型。越靠右上角的点颜色越深，这些个体在两个目标上都劣于其他点；中间区域表示被部分支配的过渡解。这张图分层清晰地展示出了支配等级，对后续模型筛选、选择决策具有指导价值。

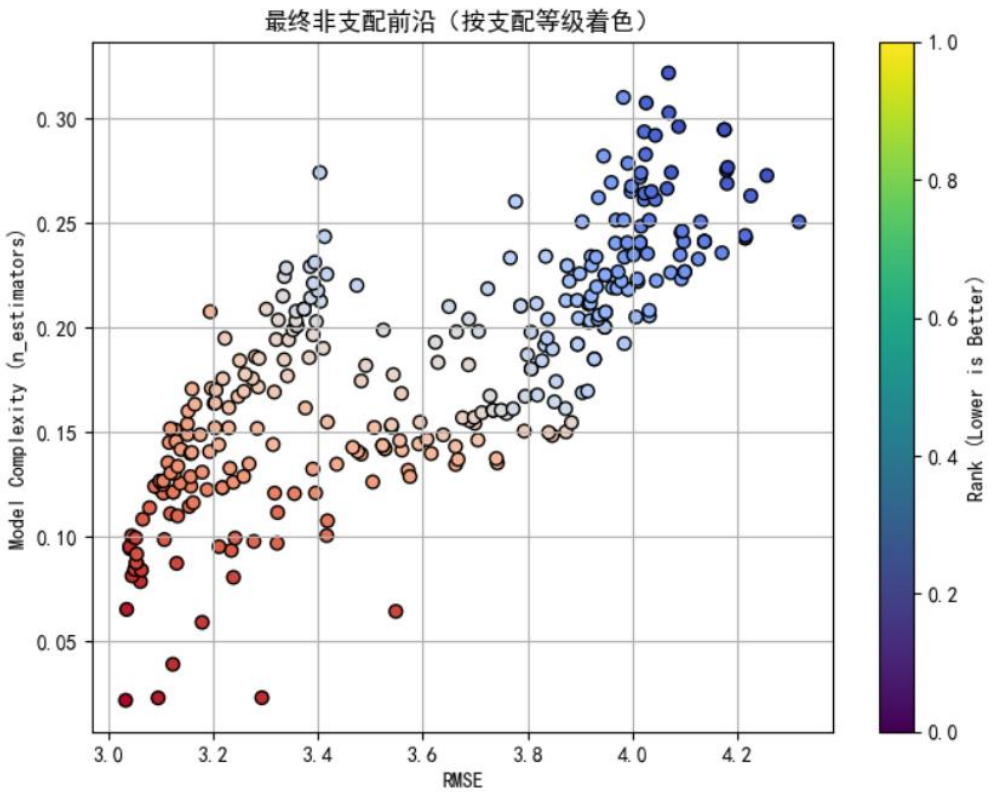

图 4-2 最终非支配前沿（按等级着色）

（3）每代最优解变化分析：考虑到本实验的代理模型用于心血管支架仿真建模，准确度应当作为高优先级，因此每代输出的最优解为 RMSE 最低的模型。图 4-5 中，散点在向左下方移动，RMSE 和复杂度双双下降，正是使用 NSGA-Ⅱ算法希望达到的效果——提升预测准确度的同时降低模型复杂度。最后几代的散点非常靠近左下角，显著优于前几代，说明算法收敛至局部最优 Pareto 前沿，进化方向正确、收敛效果优秀，RMSE 下降至 3.0335，对应复杂度为 0.022，是非常理想的表现。

观察横纵轴数值发现，数值变化不算太大，说明模型预测能力在该任务上已经逼近极限。因此在几十代优化后 RMSE 无法继续明显下降，属于平稳收敛现象，是成熟优化算法的正常表现。也证明搜索空间设定合理，NSGA-II没有陷入无效区域，在有潜力的范围内持续寻找优质解。

此外种群进化稳定，未陷入随机抖动或过拟合，没有观察到 RMSE 和复杂度在后几代突然升高或剧烈波动，每一代都在稳定微调，不断逼近最优区间。展

示出种群维持了较好多样性，未陷入局部最优。

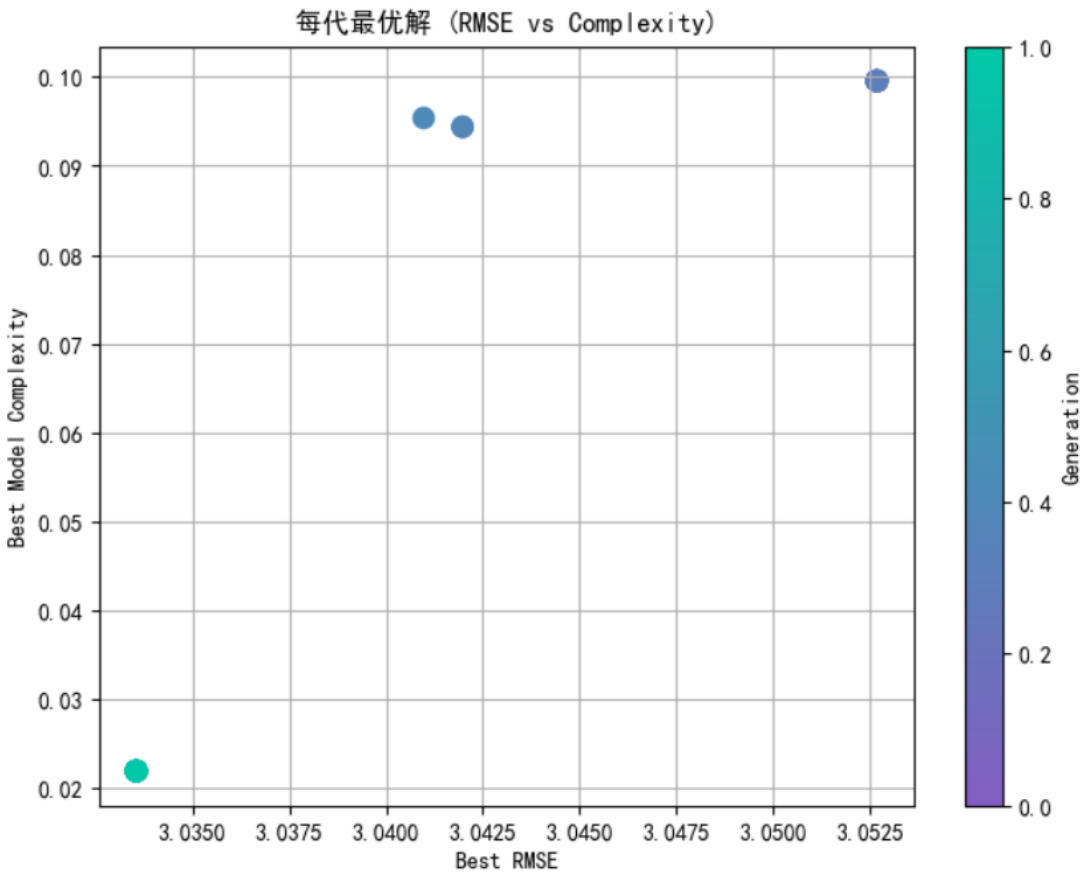

图 4-3 每代最优解变化

最终达到 RMSE=3.0335，CV RMSE=0.0888，模型复杂度为 0.0220，具体超参数配置如表 4-1 所示。

表 4-1 第 30 代最优解的参数配置

n_estimators	max_depth	learning_rate	subsample	colsample_bytree
14.6924	3.9545	0.1896	0.3560	0.2419

4.2 NSGA-Ⅱ和 SGA 优化效果的比较

为了验证 XGBoost＋NSGA-II算法的优势，在实验中还同时构建了 XGBoost＋普通遗传算法的对照组，仅以 RMSE 为单一优化目标，不考虑模型复杂度的约束，使用同样的数据集，控制其他参数相同进行优化。

GA 在初始阶段 CV RMSE 为 0.1026，第二代到第五代之间下降较为明显，说明算法确实在短期内能够快速提升模型拟合能力。但从第六代开始，图像就仅有微小波动，图 4-4 显示了 GA 的最优 RMSE 变化趋势。表 4-2 也说明算法较早陷入局部最优，缺乏全局探索能力，优化空间开发不足。

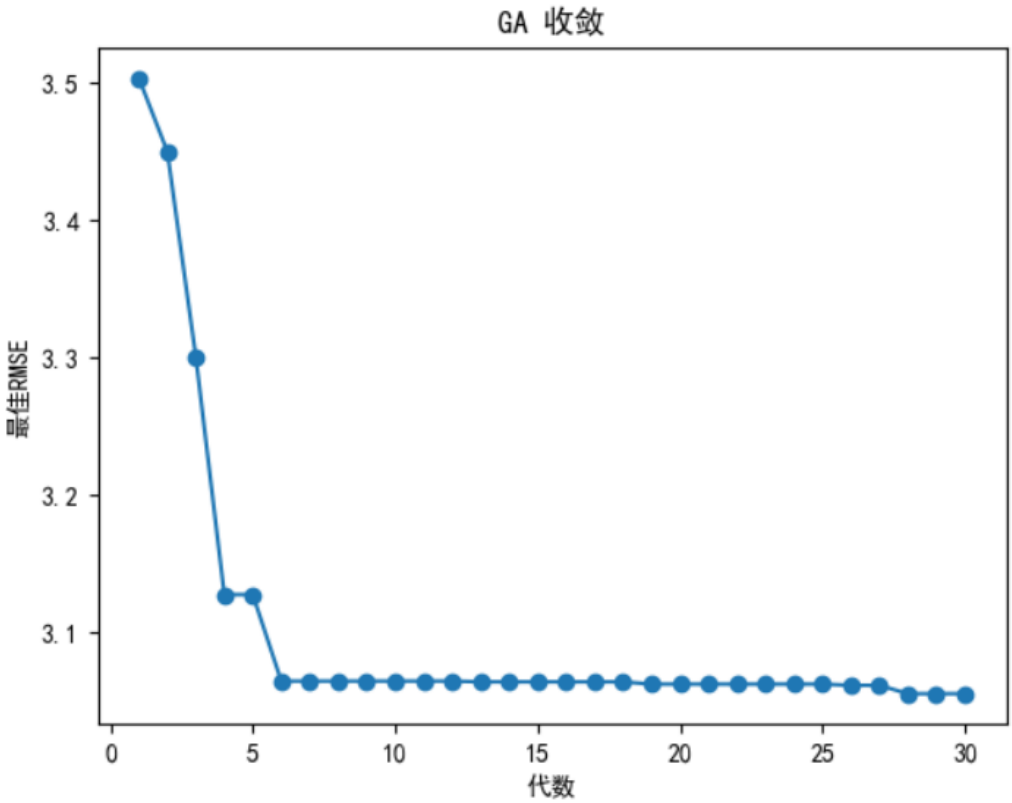

图 4-4 GA 的最优 RMSE 变化趋势

表 4-2 GA 的最优 CV RMSE

Gen_20	Gen_21	Gen_22	Gen_23	Gen_24	Gen_25	Gen_26	Gen_27	Gen_28	Gen_29	Gen_30
0.0897	0.0897	0.0897	0.0897	0.0897	0.0897	0.0897	0.0897	0.0895	0.0895	0.0895

综合两种算法的表现，NSGA-II优势明显，体现在优化路径可控性、多样性解集输出、复杂度抑制能力以及泛化可靠性方面，尤其在需要提供多方案选择的场景下，具有更高的实用性。

（1）在控制变量的对比试验中，经过三十轮训练，NSGA-II持续提升预测精度至 RMSE＝3.0355，CV RMSE=0.0888，同时引导模型结构向更简洁的方向演

化，模型复杂度从 0.1268 降至 0.0220，实现了性能与结构的双重改进。而 GA 在只考虑优化 RMSE 的情况下，最终的最优解仅为 CV RMSE=0.0895，精确度略低于 NSGA-II算法优化下的代理模型。

（2）NSGA-II提供了完整的非支配解集，其优化过程本身具有价值，使得模型选择不再局限于单一最优值，而是在精度与复杂度之间灵活权衡，提高了模型的适配性与应用价值。

（2）GA 只追求降低误差，容易在小样本下过拟合。但 NSGA-II在优化过程通过引入结构复杂度作为目标之一，显著降低了模型过拟合风险，在保证精度的前提下，有效控制了模型规模，为应用中的鲁棒性提供支撑。

（3）XGBoost 模型的可解释性并不优越，但在引入 NSGA-II算法后，预测模型输出的每个解都可追溯其对应超参数，具备更好的可解释性。在心血管支架仿真建模这样要求高安全性的场景中，选用 NSGA-II优化 XGBoost 明显更具有实用性和适配性。

第五章 总结与展望

5.1 工作总结

本文围绕优化心血管支架仿真建模的问题，实现并评估了基于 XGBoost 模型与 NSGA-II的融合代理模型。实验结果分析表明，XGBoost 模型能较为准确拟合支架设计参数与仿真性能之间的复杂非线性关系；NSGA-II优化策略在有效提升模型预测精度的同时控制了模型复杂度，XGBoost+NSGA-II代理模型在心血管支架性能预测任务中展现出优于传统方法的效果。

尽管采用的 XGBoost 模型与 NSGA-II优化算法在技术上属于成熟通用模型，但其在医疗建模场景中所具有的应用价值与适配性是本实验的亮点。和直接进行多物理场仿真建模相比，构建基于机器学习的性能预测模型可以显著降低计算成本，XGBoost 模型凭借其高精度、可解释性强和抗过拟合能力，在结构生物力学类数据的拟合中表现优越，尤其适用于心血管支架建模中存在的非线性复杂参数关系。在分类和回归中的稳健表现使其具备在医疗场景中严控“第二类错误率”的能力，对于风险敏感的医疗领域尤为重要。

XGBoost 模型的预测精度和泛化能力在很大程度上依赖于超参数的配置，实验中引入 NSGA-II算法，在超参数空间中迭代搜索最优解集，最终找到同时具备高预测精度和低复杂度的模型。心血管支架建模任务涉及非线性、高维度且较小样本的特征空间，NSGA-II 的多解搜索机制与稳定的收敛性使其中展现出优秀的适配性。通过与 XGBoost 模型协同工作，NSGA-II 在无需引入额外物理仿真的前提下实现了预测精度的有效提升，为复杂的心血管支架仿真建模提供了一种轻量、高效、可调控的优化路径。

5.2 不足与展望

随着机器学习和人工智能的发展，应用于医疗场景的代理模型仍有广阔的研究前景。本文验证了基于 XGBoost 模型与 NSGA-II的融合代理模型在心血管支

架建模问题上的可行性。为进一步提升其建模精度与临床适应性，后续还可以从以下几个方面改进。

从算法创新角看，本文主要基于现有成熟方法的整合与工程应用，虽然XGBoost 和 NSGA-II分别在机器学习和进化优化领域具有良好表现，但仍可尝试引入基于图神经网络、深度高斯过程或自适应贝叶斯优化等方法，提升模型对复杂非线性关系和高维特征交互的学习能力。

数据层面的改进对于提升模型的泛化性与医学可用性至关重要，目前模型训练主要依赖合成数据集，一定程度上限制了可落地性验证。未来可联合临床研究机构获取有限真实数据，通过模拟数据的方法扩大数据集，再进行代理模型的训练与优化，进一步提升模型可靠性。

现阶段的多目标优化仅考虑了 RMSE 与模型复杂度两个目标，未涉及预测置信度、稳定性指标或运行能耗等更多维度指标。未来可在此基础上引入三目标甚至多目标扩展结构，适应实际医疗场景中对可靠性与安全性的更高要求。

本文为心血管仿真建模的优化提供了具有可行性和较好效果的思路和方法。尽管存在诸多不足，随着之后不断改进、完善，基于 XGBoost 和 NSGA-II的融合代理模仍然有发展与应用的空间。

参考文献

[1] World Health Organization. World health statistics 2024: monitoring health for the SDGs, sustainable development goals[M]. World Health Organization, 2024.

[2] Gijsen F J H, Migliavacca F, Schievano S, et al. Simulation of stent deployment in a realistic human coronary artery[J]. Biomedical engineering online, 2008, 7: 1-11.

[3] Borhani S, Hassanajili S, Ahmadi Tafti S H, et al. Cardiovascular stents: overview, evolution, and next generation[J]. Progress in biomaterials, 2018, 7: 175-205.

[4] Tada T, Byrne R A, Simunovic I, et al. Risk of stent thrombosis among bare-metal stents, first-generation drug-eluting stents, and second-generation drug-eluting stents: results from a registry of 18,334 patients[J]. JACC: Cardiovascular Interventions, 2013, 6(12): 1267-1274.

[5] Khan W, Farah S, Domb A J. Drug eluting stents: developments and current status[J]. Journal of controlled release, 2012, 161(2): 703-712.

[6] Serruys P W, Kutryk M J B, Ong A T L. Coronary-artery stents[J]. New England Journal of Medicine, 2006, 354(5): 483-495.

[7] Jinnouchi H, Torii S, Sakamoto A, et al. Fully bioresorbable vascular scaffolds: lessons learned and future directions[J]. Nature Reviews Cardiology, 2019, 16(5): 286-304.

[8] Szabó B, Babuška I. Finite element analysis: Method, verification and validation[J]. 2021.

[9] Bhatti M M, Marin M, Zeeshan A, et al. Recent trends in computational fluid dynamics[J]. Frontiers in Physics, 2020, 8: 593111.

[10] Sun Y, Tan W, Gu Z, et al. A data-efficient strategy for building high-performing medical foundation models[J]. Nature Biomedical Engineering, 2025: 1-13.

[11] Long L, Wang R, Xiao R, et al. On llms-driven synthetic data generation, curation, and evaluation: A survey[J]. arXiv preprint arXiv:2406.15126, 2024.

[12] Naddaf M. ChatGPT generates fake data set to support hypothesis[J]. Nature, 2023, 623: 895.

[13] 韦玲玲. 心血管支架生物力学性能评估的数值研究[D]. 东南大学, 2021.

[14] Li H, Gu J, Wang M, et al. Multi-objective optimization of coronary stent using Kriging surrogate model[J]. BioMedical Engineering OnLine, 2016, 15: 275-291.

[15] Chen T, Guestrin C. Xgboost: A scalable tree boosting system[C]//Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining. 2016: 785-794.

[16] Nielsen D. Tree boosting with xgboost-why does xgboost win" every" machine learning competition?[D]. NTNU, 2016.

[17] Coello C A. An updated survey of GA-based multiobjective optimization techniques[J]. ACM Computing Surveys (CSUR), 2000, 32(2): 109-143.

[18] 路艳雪, 赵超凡, 吴晓锋, 等. 基于改进的 NSGA-II 多目标优化方法研究[J]. 计算机应用研究, 2018, 35(6): 173

[19] Audet C, Denni J, Moore D, et al. A surrogate-model-based method for constrained optimization[C]//8th symposium on multidisciplinary analysis and optimization. 2000: 4891.